Introdução

Prof. Davi Duarte de Paula

Livro da disciplina

- FERREIRA, R. et al. Preparação e Análise Exploratória de Dados. Editora Sagah, Porto Alegre, 2021.

Cronograma

Avaliação

Introdução

- Empresas cada vez mais armazenam grandes volumes de dados.
- Novas tecnologias de armazenamento surgiram
- Diferentes tipos de dados disponíveis possibilitam cruzamento de informação
- A análise de dados deve ser pautada em estatística e algoritmos.
- O segredo de uma boa análise de dados é realizar um processo de visualização utilizando diferentes perspectivas

Objetivos

- Adquirir e manipular dados de diferentes fontes.
- Limpar e visualizar dados.
- Efetuar visualizações.
- Chegar a conclusões.

Análise Exploratória de Dados (EAD)

- Os dados brutos possuem diferentes formatos.
- Necessidade de transformações, limpeza, correção de erros, entre outros processamentos.
- A análise dos dados brutos se tornam informação.
- O uso da informação resulta em conhecimento
- A tomada de decisão usando o conhecimento é sabedoria

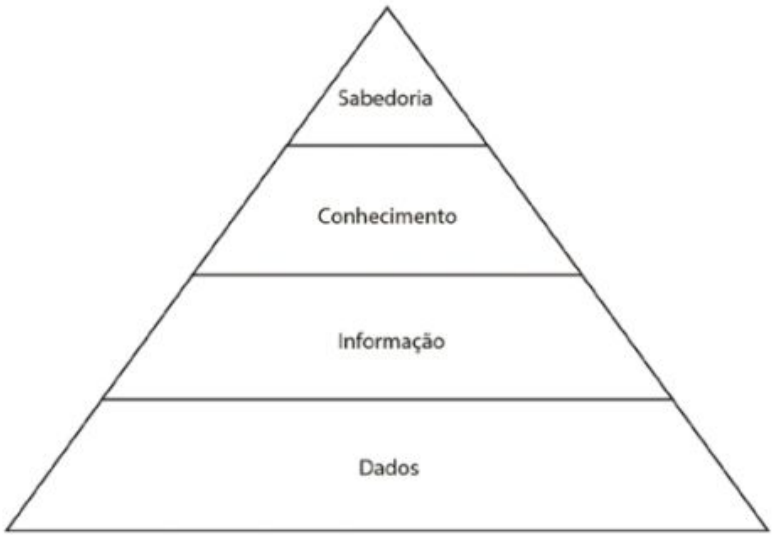

Figura 1. Pirâmide dados × informação × conhecimento × sabedoria.

Fonte: Adaptada de Nunes (2015).

Análise Exploratória de Dados (EAD)

- A AED não compete com a estatística clássica ou bayesiana — ela antecipa a modelagem, ajudando você a escolher o modelo correto.

Quadro 1. Abordagens estatísticas e estratégias utilizadas

Abordagem	Estratégia
Estatística clássica	Problema → Dados → Modelo → Análise
Estatística bayesiana	Problema → Dados → Modelo Priori → Análise
AED	Problema → Dados → Análise → Modelo

Fonte: Adaptado de Capítulo... ([2011]).

Estatística clássica

- Fluxo:
  - **Problema → Dados → Modelo → Análise**
- Primeiro você define um modelo estatístico (ex.: regressão, teste t).
- Depois verifica os dados dentro desse modelo.
- É uma abordagem confirmatória: você já tem hipóteses.
- Exemplo:
  - “Quero testar se o método A é melhor que o B.”
  - Escolhe o teste estatístico antes de explorar muito os dados.

Estatística bayesiana

- Fluxo:
  - Problema → Dados → Modelo Prior → Análise
- Igual à clássica, mas inclui conhecimento prévio (prior).
- O modelo vem antes da exploração profunda.
- Também é orientada por modelo.

AED (Análise Exploratória de Dados)

- Fluxo:
  - Problema → Dados → Análise → Modelo
- Problema principal: Primeiro você explora os dados:
  - gráficos
  - distribuições
  - outliers
  - padrões escondidos
  - correlações inesperadas
- Só depois decide qual modelo faz sentido.
- É uma abordagem exploratória e investigativa.

Classificação dos dados

- Os dados são considerados como **variáveis**.
  - Nome
  - Idade
  - Altura
  - Profissão
- Valores numéricos (quantitativos):
  - Discreto: Idade
  - Contínuo: Peso
- Valores não numéricos (qualitativo)
  - Nominais: Nome, raça, endereço
  - Ordinal: Valores categóricos, como classe social (baixa, média, alta); tamanho de roupa (pequeno, médio, grande)

Técnicas Gráficas

- Valores numéricos podem ser representados com gráficos
- Conjunto de dados contendo 2 variáveis: Produto (não numérico) e Vendas (numérico)

Produto	Vendas
Mamão	100
Laranja	200
Banana	150
Maçã	80
Melão	120
Limão	180

Figura 2. Tabela de vendas × gráfico de vendas.

Exemplo aplicado - Motos anunciadas no OLX

I4 fx

	A	B	C	D	E	F	G
1	**categoria**	**modelo**	**cilindrada**	**quilometragem**	**ano**	**url**	**preco**
2	Motos	YAMAHA XT 600 Z TE	600	150000	1988	https://sp.olx.cor	7500.0
3	Motos	HONDA CG 125 FAN	125	10000	2006	https://sp.olx.cor	3300.0
4	Motos	HONDA CG 150 TITA	150	82100	2011	https://sp.olx.cor	6300.0
5	Motos	HONDA BIZ 125 EX/ 1	125	0	2019	https://sp.olx.cor	11760.0
6	Motos	HONDA XRE	300	85000	2010	https://sp.olx.cor	8300.0
7	Motos	HONDA XRE 300/ 30(	300	7480	2018	https://sp.olx.cor	14300.0
8	Motos	HONDA TRX 420 FOU	400	0	2012	https://sp.olx.cor	13000.0
9	Motos	HONDA CG	125	70900	2003	https://sp.olx.cor	3900.0
10	Motos	HONDA	150	8500	2006	https://sp.olx.cor	4850.0
11	Motos	YAMAHA FAZER	250	105670	2008	https://sp.olx.cor	6000.0
12	Motos	KAWASAKI ER-6N 65	650	15000	2017	https://sp.olx.cor	24990.0
13	Motos	SUZUKI BANDIT N-1	Acima de 1.000	35000	2012	https://sp.olx.cor	23890.0

Exemplo aplicado - Motos anunciadas no OLX

Exemplo aplicado - Motos anunciadas no OLX

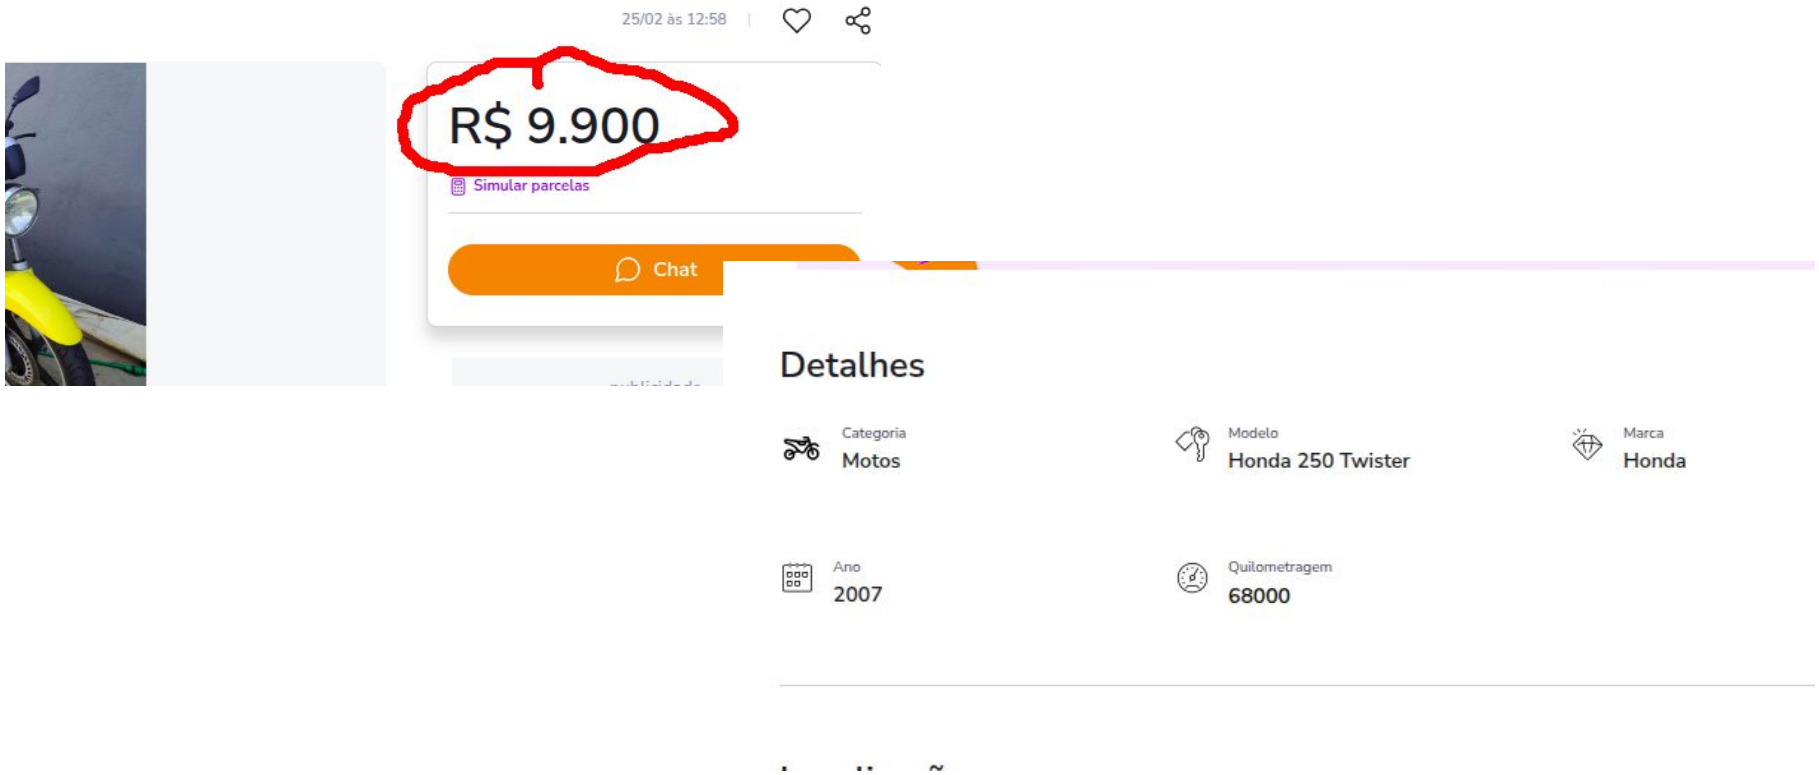

Exemplo aplicado - Motos anunciadas no OLX

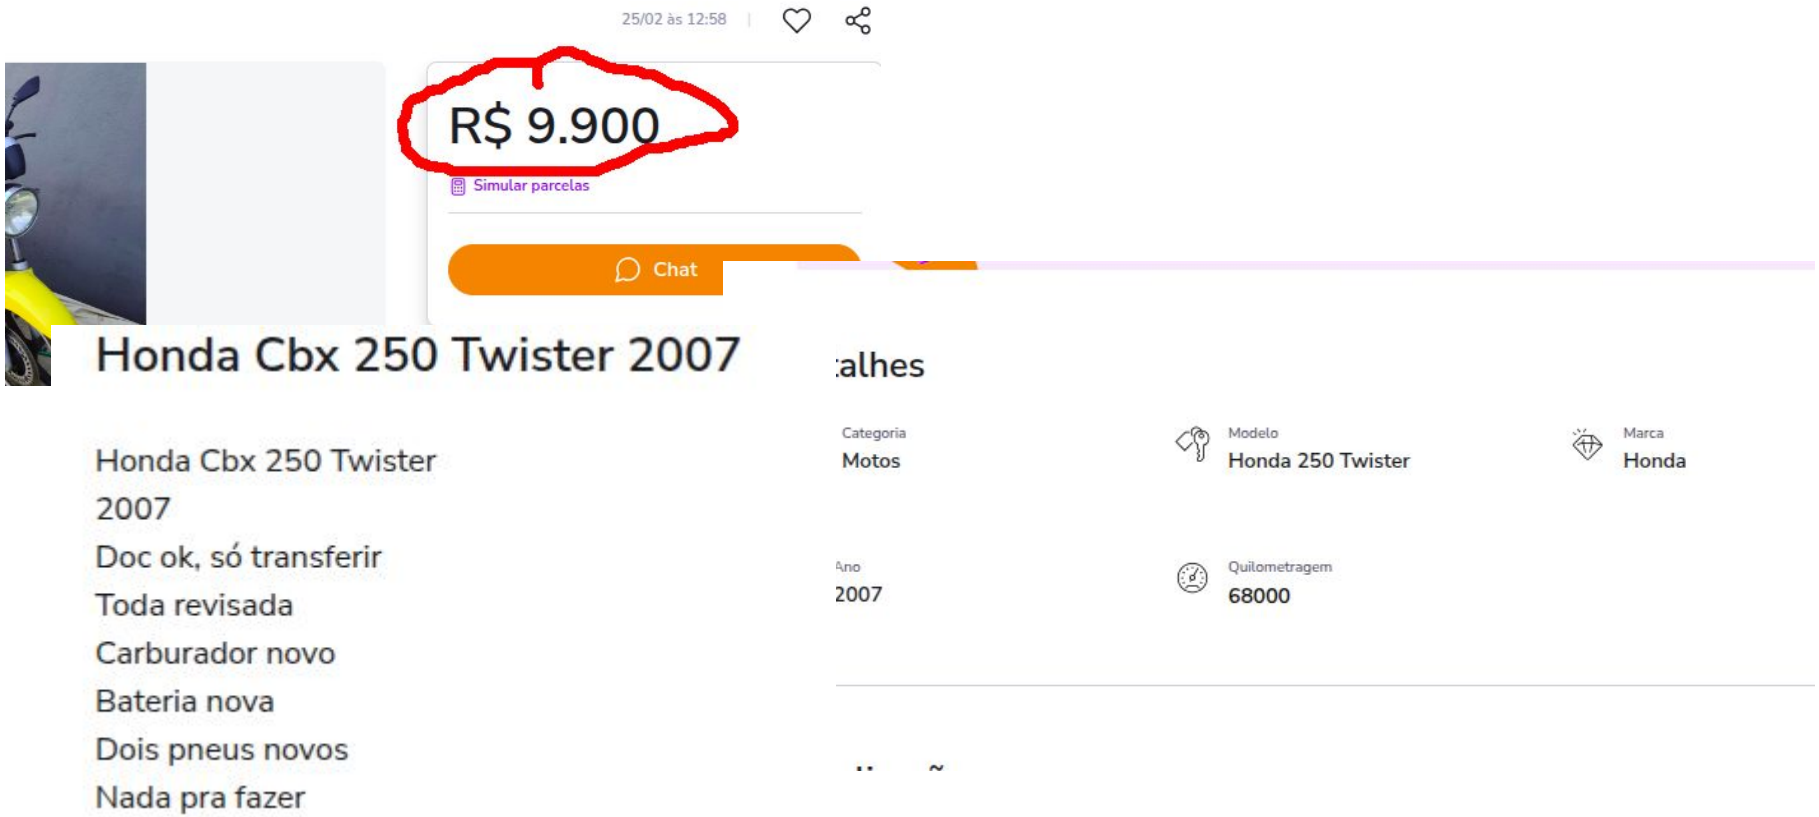

Exemplo aplicado - Motos anunciadas no OLX

- **Categoria**, **modelo**, **ano**, **cilindrada** e **preco** são as variáveis.
- Cada moto (linha da tabela) é uma **amostra**.
- A tabela inteira (conjunto de todas as linhas) é chamada de **conjunto de dados**.

Estatística Descritiva

- A estatística descritiva é composta de medidas estatísticas calculadas.

Figura 3. Etapas da estatística descritiva.

Fonte: Adaptado de Bonat, Krainski e Mayer (2020).

Coleta e Organização de Dados

- Definir objetivos e questões da pesquisa
- Em seguida, quais dados serão coletados e como
- Organizar os dados em um formato adequado.
    - Se na fonte a data de nascimento estiver em diferentes colunas, deve-se organizá-los em uma única coluna.

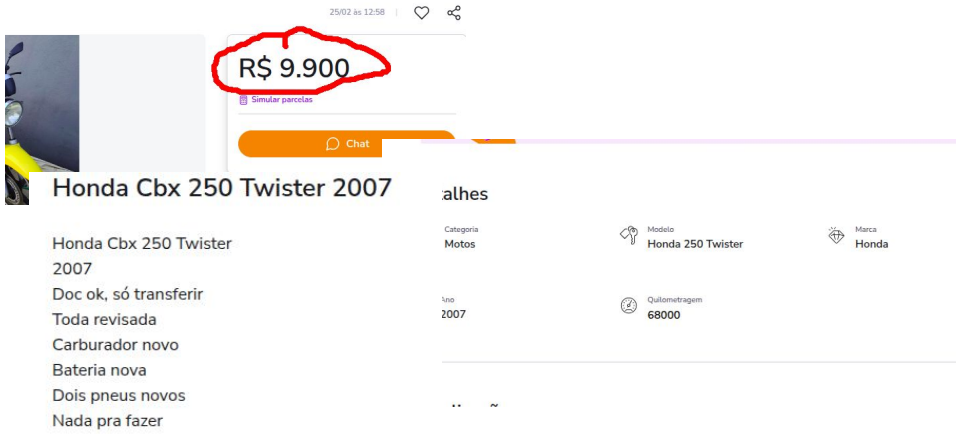

Tratamento de dados

- Melhorar ou adequar os dados coletados.
- A EAD pode ser afetada se haver informações faltantes.
- O que acontece se:
  - Algum anúncio o vendedor esquecer de colocar o valor, ano ou quilometragem da moto?
  - Em uma pesquisa, o que acontece se as pessoas não informarem informações sobre, religião, faixa salarial ou preferências pessoais?
- Técnicas possíveis:
  - Descartar amostra
  - Preencher a variável faltante com técnicas de **imputação de dados:**
    - **Média**
    - **repetição do último valor**
    - **regressão linear**

Tratamento de dados - Normalização de valores:

- Imagine que você quer prever o valor de casas usando as seguintes variáveis:

Variável	Natureza	Escala
Área (m²)	Numérica contínua	30 – 500
Número de quartos	Numérica discreta	1 – 6
Idade do imóvel (anos)	Numérica contínua	0 – 80
Distância ao centro (km)	Numérica contínua	0.5 – 40
Renda média do bairro (R$)	Numérica contínua	1.500 – 25.000

Tratamento de dados - Normalização de valores:

- Perceba o problema:
  - Área pode ter valores como 250
  - Distância pode ser 3.2
  - Renda pode ser 18000
- As escalas são completamente diferentes.
- Dependendo da técnica utilizada, variável renda do bairro pode dominar o cálculo simplesmente porque seus números são maiores.
- A normalização muda os valores para a mesma faixa (ex: 0 até 100), mas mantendo a proporção.

Tratamento de dados - Outliers

- Valores que divergem muito da média do restante dos valores.
- Pode ser causado por erros na entrada ou processamento.
  - Ou podem até ser valores reais excepcionais.

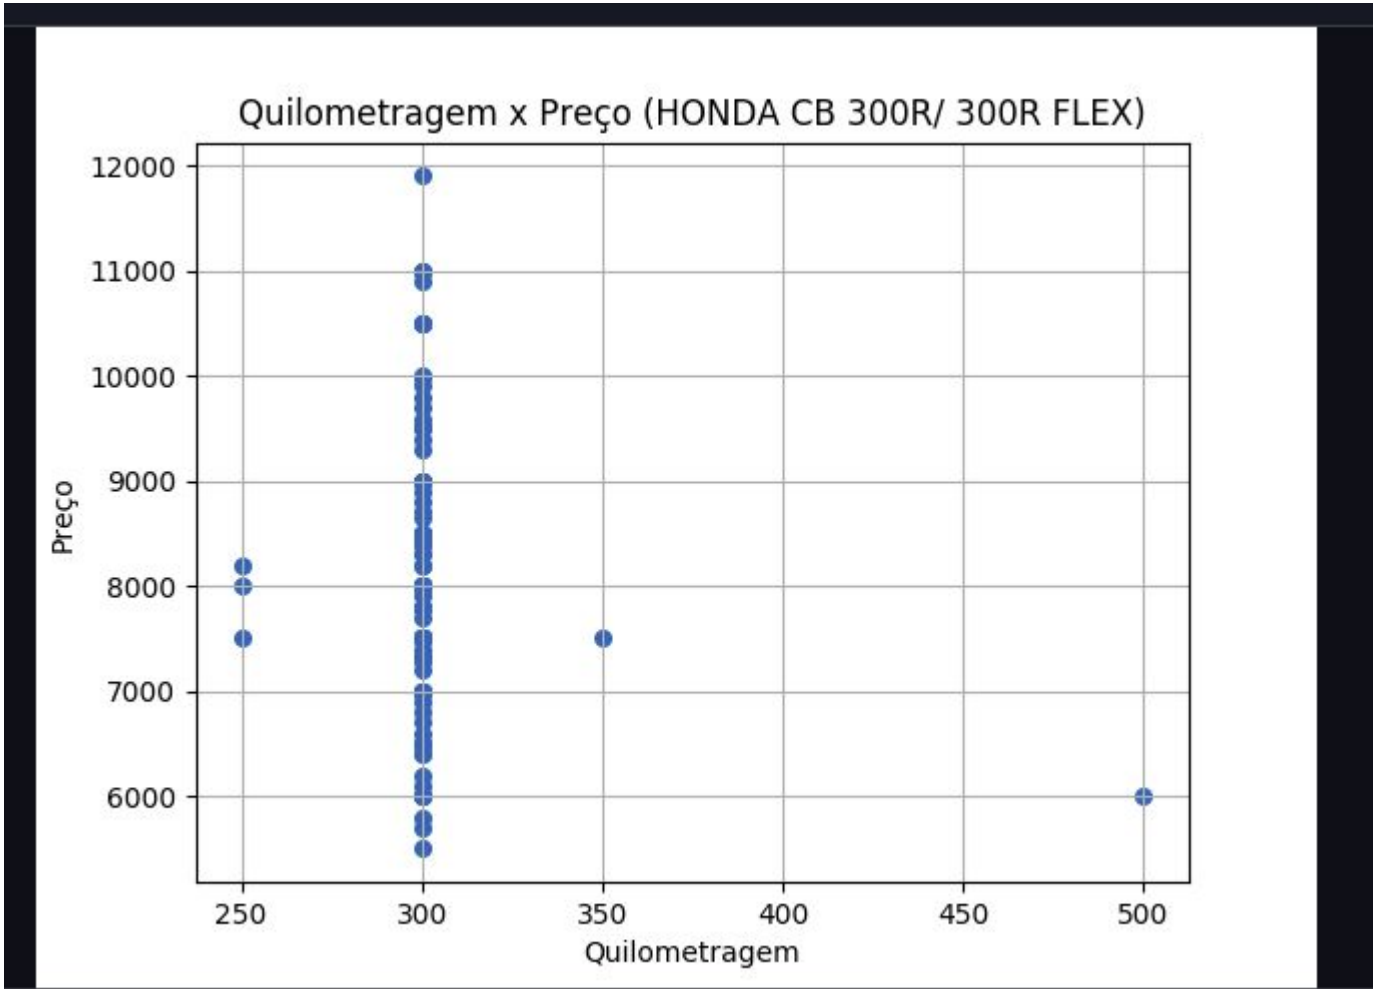
Quilometragem x Preço (HONDA CB 300R/ 300R FLEX)
Preço
12000
11000
10000
9000
8000
7000
6000
250
300
350
400
450
500
Quilometragem

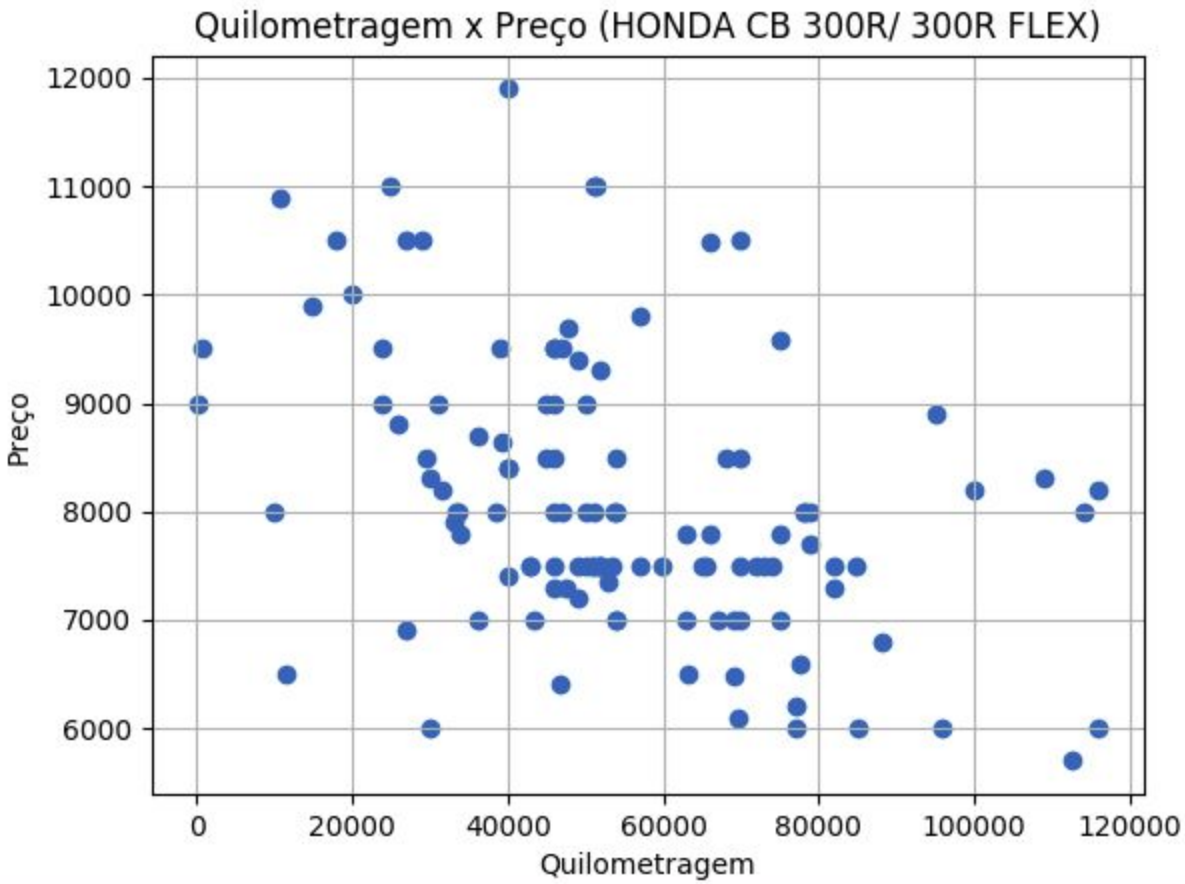
Quilometragem x Preço (HONDA CB 300R/ 300R FLEX)
Preço
12000
11000
10000
9000
8000
7000
6000
0
20000
40000
60000
80000
100000
120000
Quilometragem

Análise de Dados

- Para a etapa de análise dos dados, podem ser realizadas as análises univariada, multivariada e de correlações.
- Análise Univariada:
  - Em uma análise da variável idade, podemos obter, em uma coleta de dados, os seguintes valores: {18, 19, 18, 21, 21, 18}. A frequência dessa variável idade seria assim definida: {18 — 3 ocorrências, 19 — 1 ocorrência e 21 — 2 ocorrências}.

Análise de Dados

- Análise Multivariada:
  - Estabelece relações entre duas ou mais variáveis. Por exemplo, a altura da pessoa mediante o sexo e a idade.
- Análise de Correlação:
  - Ocorrem quando dois acontecimentos, os quais não necessariamente são causalidades, tendem a ocorrer de forma sincronizada.
  - Inflação alta tende a aumentar o desemprego.
  - Se um cliente almoça todos os dias no mesmo restaurante, a tendência é que as variáveis “frequência semanal de almoço” e “satisfação com a comida”

Apresentação e Interpretação dos Dados

- Usando Tabela
- Usando gráficos
  - Linha
  - Pizza
  - Barras
  - Setores
  - Etc

Apresentação e Interpretação dos Dados

-

Estado Civil	Frequência
Casado	26
Solteiro	18
Separado	8

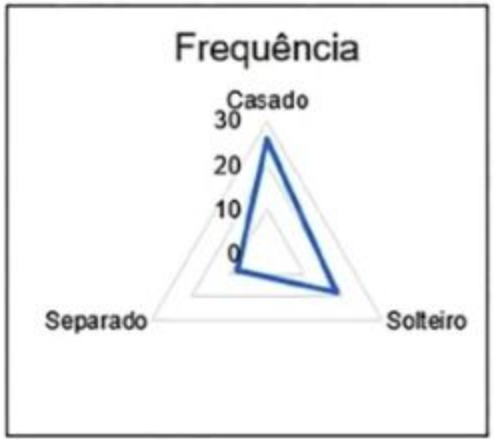

Figura 4. Gráfico de radar.

Apresentação e Interpretação dos Dados

- A partir da apresentação dos dados, a etapa de interpretação dos dados permite definir o modelo a ser aplicado para o problema em questão.
- Iniciamos com a análise dos dados para depois definir o modelo a ser utilizado.