Aula 3 - Análise univariada de dados

Prof. Davi Duarte de Paula

População e amostra

- **População:** é o conjunto completo de elementos (indivíduos, objetos ou medidas) que possuem uma característica de interesse em um estudo.
- **Amostra:** é um subconjunto da população, selecionado com o objetivo de representá-la em análises estatísticas.

Análise Univariada

- Estudo de uma variável por vez
- A análise de dados univariados é a forma mais simples de análise, pois a informação lida com apenas uma quantidade que muda
- Permite descrever e resumir dados

Análise Univariada

- Facilita a interpretação dos dados
- Base para análises mais complexas
- Permite estimativas estatísticas iniciais

Análise Univariada

- Consiste, basicamente:
  - 1 - classificar cada variável em tipo:
    - qualitativa
    - quantitativa,
  - 2º - Obter tabelas, gráficos e/ou medidas que resumem essas variáveis.

Conjunto de dados de alunos

(a)

	A	B	C	D	E	F	G	H
1	Id,Turma,Sexo,Idade,Alt,Peso,Filhos,Fuma,Toler,Exerc,Cine,OpCine,TV,OpTV							
2	1,A,F,17,1.60,60.5,2,NAO,P,0,1,B,16,R							
3	2,A,F,18,1.69,55.0,1,NAO,M,0,1,B,7,R							
4	3,A,M,18,1.85,72.8,2,NAO,P,5,2,M,15,R							
5	4,A,M,25,1.85,80.9,2,NAO,P,5,2,B,20,R							
6	5,A,F,19,1.58,55.0,1,NAO,M,2,2,B,5,R							
7	6,A,M,19,1.76,60.0,3,NAO,M,2,1,B,2,R							
8	7,A,F,20,1.60,58.0,1,NAO,P,3,1,B,7,R							
9	8,A,F,18,1.64,47.0,1,SIM,I,2,2,M,10,R							
10	9,A,F,18,1.62,57.8,3,NAO,M,3,3,M,12,R							
11	10,A,F,17,1.64,58.0,2,NAO,M,2,2,M,10,R							
12	11,A,F,18,1.72,70.0,1,SIM,I,10,2,B,8,N							
13	12,A,F,18,1.66,54.0,3,NAO,M,0,2,B,0,R							
14	13,A,F,21,1.70,58.0,2,NAO,M,6,1,M,30,R							
15	14,A,M,19,1.78,68.5,1,SIM,I,5,1,M,2,N							
16	15,A,F,18,1.65,63.5,1,NAO,I,4,1,B,10,R							
17	16,A,F,19,1.63,47.4,3,NAO,P,0,1,B,18,R							
18	17,A,F,17,1.82,66.0,1,NAO,P,3,1,B,10,N							
19	18,A,M,18,1.80,85.2,2,NAO,P,3,4,B,10,R							
20	19,A,F,20,1.60,54.5,1,NAO,P,3,2,B,5,R							
21	20,A,F,18,1.68,52.5,3,NAO,M,7,2,B,14,M							
22	21,A,F,21,1.70,60.0,2,NAO,P,8,2,B,5,R							
23	22,A,F,18,1.65,58.5,1,NAO,M,0,3,B,5,R							

(b)

Id	Identificação do aluno
Turma	Turma a que o aluno foi alocado (A ou B)
Sexo	F se feminino, M se masculino
Idade	Idade em anos
Alt	Altura em metros
Peso	peso em quilogramas
Filhos	número de filhos na família
Fuma	Hábito de fumar SIM ou NAO
Toler	Tolerância ao cigarro: (I) – indiferente (P) – incomoda um pouco (M) – incomoda muito
Exerc	Horas de atividades físicas por semana
Cine	Número de vezes que vai a cinema por semana
OpCine	Opinião sobre as salas de cinema da cidade: (B) regular e boa (M) muito boa
TV	Horas gastas assistindo TV por semana
OpTV	Opinião a respeito da qualidade da programação da TV (R) ruim (M) média (B) boa (N) não sabe

Histograma

- Um histograma é uma representação gráfica precisa da distribuição de dados numéricos contínuos a partir de apenas uma variável.
- Os dados são divididos em várias posições, e o número de observações por posição é representado pela altura da barra

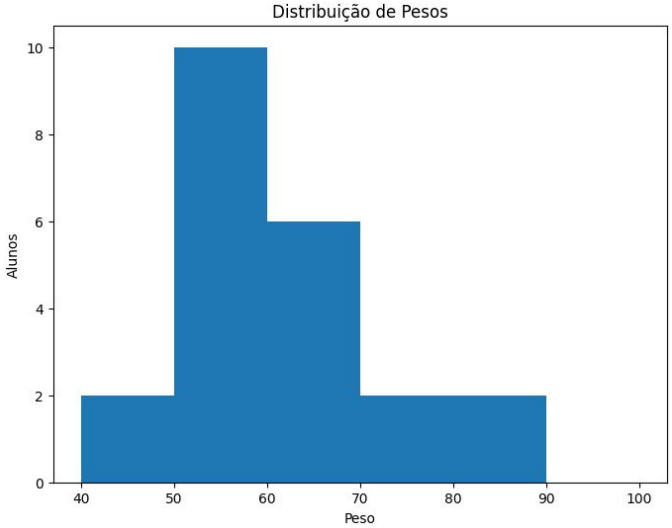

Gráfico de barras

- Mostra a relação entre uma variável numérica e uma variável categórica

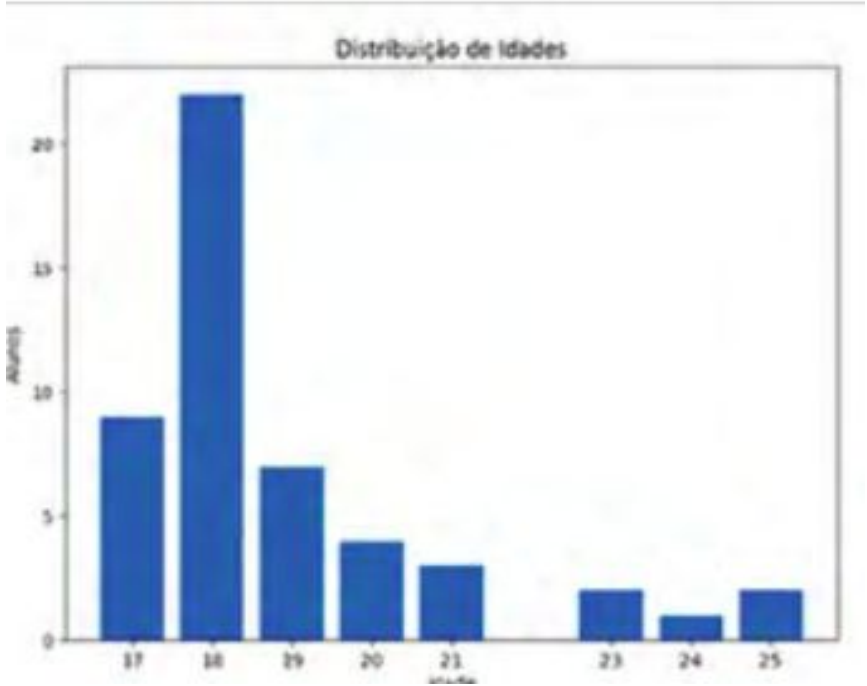

Box-plot

- Fornece um bom resumo de uma ou várias variáveis numéricas.
- A linha que divide a caixa em duas partes representa a mediana dos dados.
- O final da caixa mostra os quartis superior e inferior.
- As linhas extremas mostram os valores mais alto e mais baixo, excluindo valores discrepantes

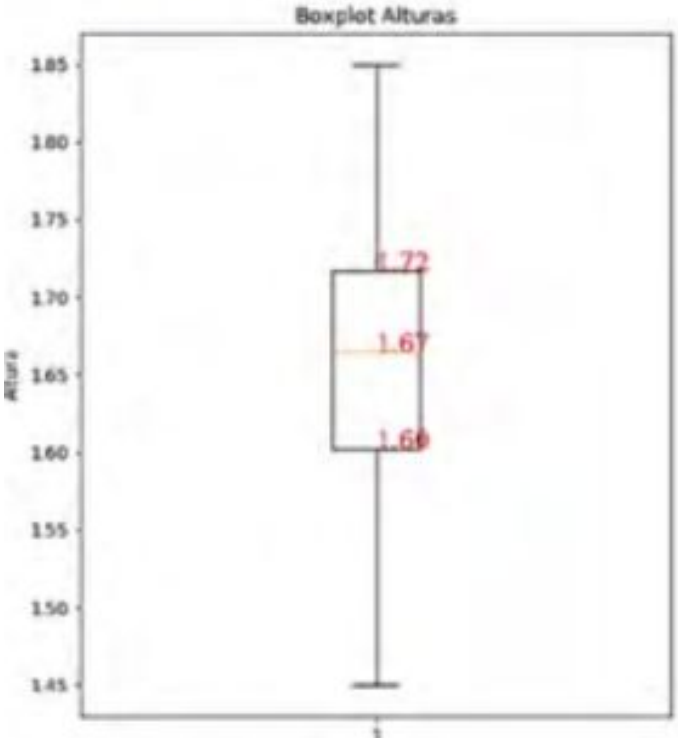

Violin Plot

- Permite visualizar a distribuição de uma variável numérica para um ou vários grupos.
- É muito próximo de um box-plot, mas permite uma compreensão mais profunda da densidade.
- Esses gráficos são particularmente adaptados quando a quantidade de dados é enorme e há impossibilidade de mostrar observações individuais.

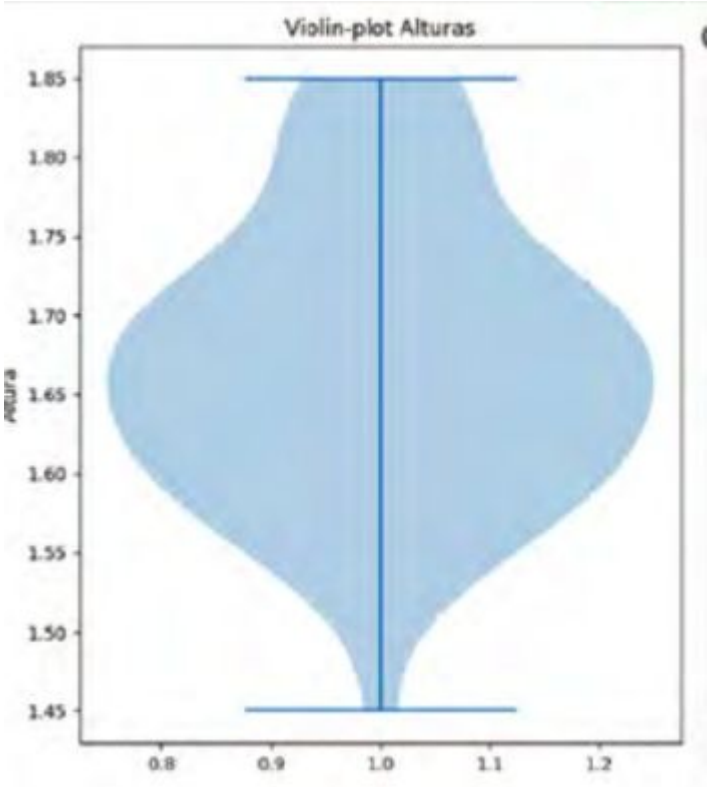

Tipos de Variáveis

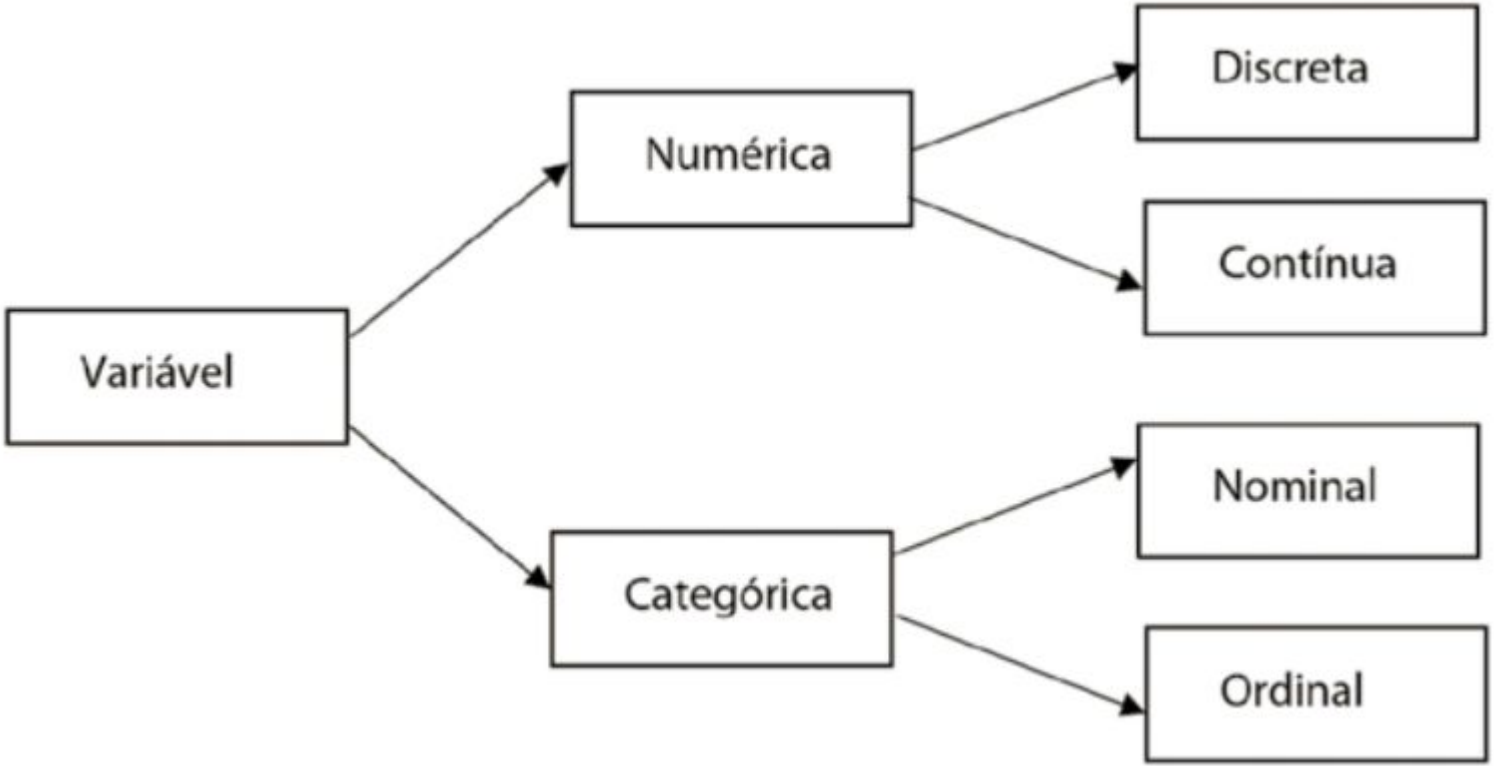

Tipos de Variáveis

- Variáveis numéricas são divididas em
  - discretas, que assumem valores inteiros, a exemplo da idade
  - contínuas, que assumem qualquer valor no intervalo de números reais, a exemplo da altura e peso.
- Variáveis categóricas são divididas em:
  - nominais, que ocorrem quando as categorias não têm uma ordem natural, a exemplo de nome e sexo
  - ordinais, que ocorrem quando as categorias podem ser ordenadas, a exemplo de tamanho (pequeno, médio e grande) e grau de instrução (básico, médio, graduação e pós-graduação).

Tipos de Variáveis

-

Variável	Classificação
Id	Numérica discreta
Turma	Categórica nominal
Sexo	Categórica nominal
Idade	Numérica discreta
Alt	Numérica contínua
Peso	Numérica contínua
Filhos	Numérica discreta

Tipos de Variáveis

-

Fuma	Categórica nominal
Toler	Categórica ordinal
Exerc	Numérica discreta
Cine	Numérica discreta
OpCine	Categórica ordinal
TV	Numérica discreta
OpTV	Categórica ordinal

Variável categórica nominal

- A variável **Fuma** do nosso arquivo de exemplo é categórica nominal. Desta forma, podemos obter com ela:
  - uma tabela de frequências (absolutas e/ou relativas);
  - um gráfico de barras ou de setores;
  - a moda, ou seja, o valor que ocorre com maior frequência

Variável categórica ordinal

- A variável **Toler**, que se refere à tolerância ao cigarro, é categórica ordinal, já que existe uma ordem nas respostas.
- O gráfico de setores não é adequado para este tipo de variável, por não expressar a ordem dos possíveis valores.
- Usa-se então apenas um gráfico de barras.

Variável numérica discreta

- A variável **Filhos** (número de filhos na família) é boa para ilustrar algumas análises que podem ser feitas com uma variável numérica discreta.
- Frequências absolutas e relativas podem ser obtidas.
- Neste caso, assumimos que cada valor numérico é uma categoria e construímos as tabelas de frequência como se a variável fosse categórica ordinal.

Variável Numérica Contínua

- Para fazermos uma tabela de frequências de uma variável contínua, precisamos primeiro agrupar os dados em classes preestabelecidas.
- A escolha dos intervalos de classe geralmente é arbitrária, e a familiaridade do pesquisador com os dados é que indicará quantas e quais classes devem ser utilizadas.
- Normalmente, utilizamos um dos três possíveis gráficos para variáveis contínuas: o de **dispersão**, o **histograma** e o de **ramo e folhas**.

Quarteto de Anscombe

- Ilustra a importância de explorar os dados antes de se fazer uma análise estatística
- Quarteto de Anscombe é o nome dado a quatro conjuntos de dados que têm estatísticas descritivas quase idênticas (como a média e a variância) mas que têm distribuições muito diferentes e aparências muito distintas quando exibidos por meio de gráficos.
- Cada conjunto de dados consiste em onze pontos (X, Y). Eles foram construídos em 1973 pelo estatístico Francis Anscombe, com o objetivo de demonstrar tanto a importância de visualizarmos os dados antes de analisá-los quanto o efeito dos outliers e de outras observações influentes nas propriedades estatísticas.
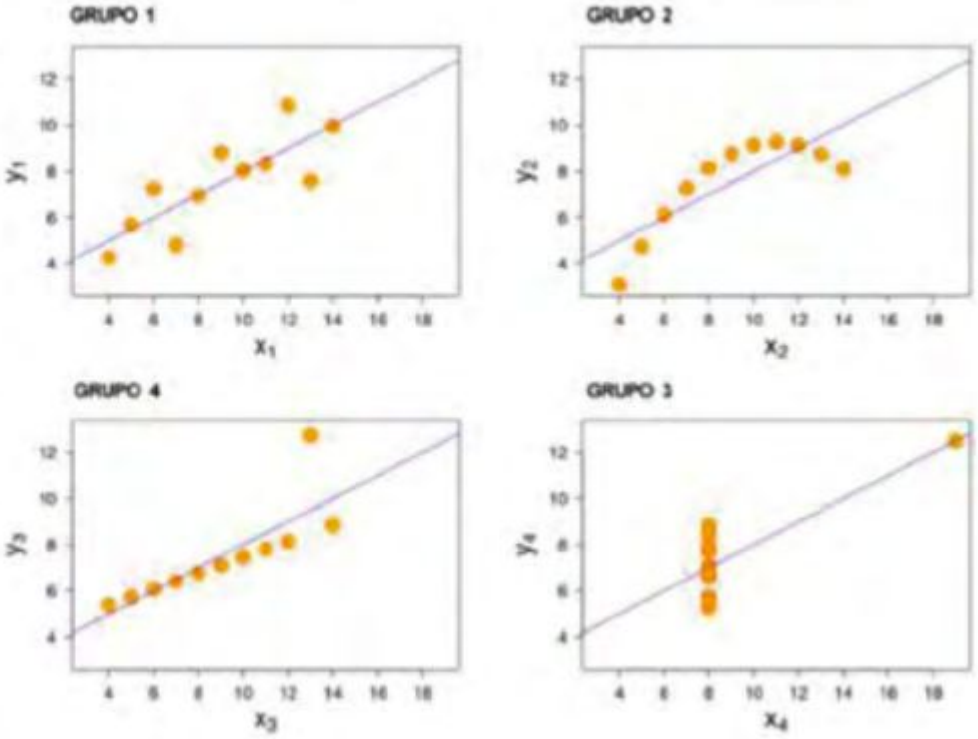
GRUPO 1		GRUPO 2		GRUPO 3		GRUPO 4	
X	Y	X	Y	X	Y	X	Y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.74	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.1	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.1	4	5.39	19	12.5
12	10.84	12	9.13	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89